ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о командном программном проекте на тему:

Прогнозирование динамики графа платежей на основе открытых платежных данных

(промежуточный, этап 1)

Выполнили студенты:

группы #БПМИ233, 3 курса	Кречетов Роман Константинович
группы #БПМИ233, 3 курса	Романюков Егор Сергеевич
группы #БПМИ2310, 3 курса	Шеин Илья Антонович

Принял руководитель проекта:

Филатов Дмитрий Станиславович
Исполнительный директор по исследованию данных
ПАО "Сбербанк"

Москва 2026

Содержание

Аннотация **3**

Список ключевых слов **3**

Введение **3**

Обзор литературы **3**

Обзор библиотек 3

Обзор работ про биткоин 3

Обзор моделей для прогнозирования 3

1 Задача **3**

1.1 Постановка задачи 3

1.2 Датасет 3

1.3 Семлирование негативных рёбер 3

2 Модели **3**

2.1 Базовые решения 3

2.2 EAGLE 3

2.3 GraphMixer 5

2.3.1 Архитектура модели GraphMixer 5

2.4 GLFormer 7

2.5 DyGFormer 7

2.6 HyperEvent 7

3 Эксперименты **7**

3.1 Результаты экспериментов 7

4 Фреймворк **7**

5 CUDA **7**

A Пример секции аппендикса **8**

B Описание применения генеративных моделей **8**

Аннотация

Список ключевых слов

Введение

Обзор литературы

1 Задача

1.1 Постановка задачи

1.2 Датасет

1.3 Семлирование негативных рёбер

2 Модели

2.1 Базовые решения

2.2 EAGLE

Предлагаемая модель EAGLE (Efficient and Effective GrAph modEL for temporal Link prEdiction) представляет собой легковесную архитектуру, предназначенную для решения задачи предсказания временных связей в динамических графах. Основной принцип, заложенный в основу EAGLE, заключается в раздельном и явном учете двух ортогональных, но взаимодополняющих аспектов, значимых для прогнозирования взаимодействий: краткосрочной темпоральной активности узла, отражающей его непосредственные предпочтения, и долгосрочных глобальных структурных паттернов, определяющих его позицию в сети. В отличие от существующих темпоральных графовых нейронных сетей, использующих сложные механизмы, такие как многослойные трансформеры, рекуррентные блоки или модули памяти, EAGLE достигает высокой эффективности за счет простоты своих компонентов, агрегируя информацию лишь из ограниченного набора наиболее релевантных узлов. Архитектура EAGLE состоит из трех ключевых компонентов: модуля, учитывающего фактор времени (time-aware module), модуля, учитывающего структурную информацию (structure-aware module), и адаптивного механизма их объединения.

Модуль, учитывающий фактор времени, фокусируется на захвате краткосрочных темпоральных трендов. Для заданного узла v в момент времени t из всего множества его исторических соседей $N_v(t)$ отбираются k_r наиболее поздних по времени взаимодействия соседей, формируя множество $N_v(t, k_r)$. Такой подход обоснован экспериментально: недавние взаимодействия являются наиболее сильными индикаторами будущих связей. Далее, для узла v вычисляется его временное представление $\mathbf{h}_v^{\text{ta}}(t)$ путем усреднения конкатенации признаков самих соседей $\mathbf{x}_{v_i}(t)$ и признаков ребер $\mathbf{e}_{v,v_i}(\tau_i)$, связывающих их с узлом v:

$$\mathbf{h}_v^{\text{ta}}(t) = \frac{1}{k_r} \sum_{(v_i, \mathbf{e}_{v,v_i}(\tau_i), \tau_i) \in N_v(t, k_r)} [\mathbf{x}_{v_i}(t), \mathbf{e}_{v,v_i}(\tau_i)].$$

Для пары узлов (v, u) вероятность наличия связи на основе временного модуля $s_{v,u}^{\text{ta}}(t)$ вычисляется с помощью двухслойного перцептрона (MLP), на вход которого подается конкатенация их временных представлений:

$$s_{v,u}^{\text{ta}}(t) = \sigma(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1[\mathbf{h}_v^{\text{ta}}(t), \mathbf{h}_u^{\text{ta}}(t)] + \mathbf{b}_1) + \mathbf{b}_2),$$

где σ — сигмоидная функция, а $\mathbf{W}_1, \mathbf{W}_2, \mathbf{b}_1, \mathbf{b}_2$ — обучаемые параметры.

Модуль, учитывающий структурную информацию, предназначен для захвата долгосрочных глобальных зависимостей. Его работа основана на алгоритме темпорального персонализированного ранжирования PageRank (T-PPR), который обобщает классический PPR на динамические графы, присваивая больший вес более поздним взаимодействиям при вычислении вероятностей перехода. Для узла v вычисляется вектор $\boldsymbol{\pi}_v(t)$, где каждый элемент $\boldsymbol{\pi}_v(t)[u]$ представляет собой T-PPR-оценку влияния узла u на узел v в момент времени t. Для каждого узла отбирается множество из k_s узлов, имеющих наибольшие T-PPR-оценки. Структурная связь между узлами v и u оценивается путем суммирования произведений их T-PPR-оценок для общих влиятельных узлов:

$$s_{v,u}^{\text{sa}}(t) = \sum_{v_i \in N_v(\boldsymbol{\pi}_v(t), k_s) \cap N_u(\boldsymbol{\pi}_u(t), k_s)} \boldsymbol{\pi}_v(t)[v_i] \cdot \boldsymbol{\pi}_u(t)[v_i].$$

Полученная величина $s_{v,u}^{\text{sa}}(t)$ является детерминированной и не требует обучения, что делает этот модуль исключительно легковесным.

Финальный гибридный модуль объединяет выходы временного и структурного компонентов, используя адаптивный механизм взвешивания. Основная идея заключается в том, чтобы динамически регулировать вклад временного модуля в зависимости от того, насколько

недавними были взаимодействия узлов. Для этого для узла v вычисляется средний интервал времени $\bar{t}_v$ до его k_r последних соседей. Адаптивный вес для временной оценки задается как $\exp(-\bar{t}_v)$. Итоговая гибридная оценка для пары (v, u) определяется как:

$$s_{v,u}^{\text{hybrid}}(t) = \lambda \cdot (\exp(-\bar{t}_v) + \exp(-\bar{t}_u)) \cdot s_{v,u}^{\text{ta}}(t) + s_{v,u}^{\text{sa}}(t),$$

где λ — гиперпараметр, регулирующий общий баланс между двумя источниками информации. Такая схема позволяет модели автоматически отдавать приоритет недавним взаимодействиям для активно меняющихся узлов и полагаться на глобальную структуру для узлов с редкой или давней активностью. Вся архитектура EAGLE, благодаря использованию простых операций усреднения, MLP ограниченной глубины и эффективному обновлению T-PPR, демонстрирует линейную или почти линейную вычислительную сложность относительно числа новых событий и предсказываемых пар узлов.

2.3 GraphMixer

2.3.1 Архитектура модели GraphMixer

Модель GraphMixer (Cong et al., 2023) представляет собой архитектуру для прогнозирования связей в темпоральных графах, разработанную с целью минимизации концептуальной и технической сложности. В отличие от преобладающих подходов, использующих рекуррентные нейронные сети (RNN) или механизмы самовнимания (SAM), GraphMixer построена исключительно на основе многослойных перцептронов (MLP) и операции пулинга соседей, что позволяет достичь конкурентоспособной производительности без усложнения архитектуры. Модель состоит из трёх основных функциональных модулей: кодировщика связей, кодировщика узлов и классификатора связей.

Кодировщик связей (link-encoder) предназначен для обобщения информации о темпоральных связях, ассоциированных с каждым узлом. Для узла v_i его темпоральная история представляет собой упорядоченный по времени набор взаимодействий с другими узлами. На вход кодировщика подаются данные о K наиболее поздних взаимодействиях, где K — гиперпараметр, зависящий от набора данных. Каждое взаимодействие в момент времени t кодируется путём конкатенации вектора признаков связи $\mathbf{x}_{ij}^{\text{link}}(t)$ с результатом применения фиксированной функции временного кодирования $\cos(t\boldsymbol{\omega})$ к относительному времени $(t_0 - t)$, где t_0 — целевой момент прогнозирования. Вектор $\boldsymbol{\omega} = \{\alpha^{-(i-1)/\beta}\}_{i=1}^{d}$ содержит фиксированные, не обучаемые в процессе тренировки частотные компоненты, где параметры α и β выби-

раются таким образом, чтобы гарантировать различимость всех временных меток в заданном диапазоне. Для унификации длины входных последовательностей используется дополнение нулями (zero-padding) до фиксированной длины K, что позволяет модели учитывать частоту взаимодействий узла. Полученная матрица $\mathbf{T}_i(t_0)$ размерности $K \times d_{\text{input}}$ обрабатывается однослойным MLP-Mixer (Tolstikhin et al., 2021). Архитектура MLP-Mixer последовательно применяет два преобразования: сначала токен-микшер (token-mixer), который позволяет обмениваться информацией между различными взаимодействиями (токенами) в последовательности, затем канальный микшер (channel-mixer), обрабатывающий признаки независимо для каждого токена. Оба микшера используют операции линейных преобразований, функции активации GeLU и нормализацию слоя (LayerNorm). Итоговым представлением темпоральной информации узла v_i является вектор $\mathbf{t}_i(t_0)$, получаемый усреднением (mean-pooling) выходной матрицы канального микшера.

Кодировщик узлов (node-encoder) предназначен для агрегации статической информации об узле и его ближайшем окружении. Представление узла формируется на основе его собственных признаков $\mathbf{x}_i^{\text{node}}$ и признаков его 1-соседей, с которыми были зафиксированы взаимодействия за временной интервал $[t_0 - T, t_0]$, где T — гиперпараметр. Итоговый вектор $\mathbf{s}_i(t_0)$ вычисляется как сумма собственных признаков узла и среднего значения признаков его соседей: $\mathbf{s}_i(t_0) = \mathbf{x}_i^{\text{node}} + \text{Mean}\{\mathbf{x}_j^{\text{node}} \mid v_j \in \mathcal{N}(v_i; t_0 - T, t_0)\}$. В случае отсутствия атрибутивных признаков узлов в наборе данных используются one-hot векторы для идентификации узлов.

Классификатор связей (link classifier) является двухслойным MLP, который на основе объединённых представлений пары узлов вычисляет вероятность существования связи между ними в момент времени t_0. Для узлов v_i и v_j итоговые представления $\mathbf{h}_i(t_0) = [\mathbf{s}_i(t_0) \| \mathbf{t}_i(t_0)]$ и $\mathbf{h}_j(t_0) = [\mathbf{s}_j(t_0) \| \mathbf{t}_j(t_0)]$ конкатенируются и подаются на вход классификатора: $p_{ij} = \text{MLP}([\mathbf{h}_i(t_0) \| \mathbf{h}_j(t_0)])$.

Важной архитектурной особенностью GraphMixer является рассмотрение темпорального графа как неориентированного. Это позволяет кодировщику узлов извлекать информацию о частоте взаимных связей между узлами в недавнем прошлом, что является значимым признаком для прогнозирования. Выборка ограничивается только 1-соседями с наиболее поздними временными метками, что снижает зашумленность входных данных и уменьшает вычислительную сложность по сравнению с методами, использующими многошаговую или равномерную выборку соседей.

2.4 GLFormer

2.5 DyGFormer

2.6 HyperEvent

3 Эксперименты

3.1 Результаты экспериментов

Таблица 3.1: Эксперименты, сравнивающие различные модели

Модель	test MRR	val MRR	test H@1	test H@10
CN	0.64	0.70	0.55	0.81
AA	0.63	0.69	0.54	0.79
CN + MLP	0.62	0.69	0.53	0.79
Jaccard	0.55	0.63	0.45	0.75
RF	0.52	0.56	0.41	0.74
PA	0.50	0.53	0.41	0.69
Catboost	0.49	0.54	0.38	0.73
LogReg	0.35	0.36	0.26	0.52
EAGLE	0.46	0.53	0.35	0.67
GraphMixer	0.22	0.25	0.13	0.40
GLFormer	0.09	0.07	0.11	0.20
DyGFormer	-	>0.63	-	-
HyperEvent	-	-	-	-

4 Фреймворк

5 CUDA

A Пример секции аппендикса

B Описание применения генеративных моделей

всё сами